



UNIVERSIDADE FEDERAL DE SANTA CATARINA  
CENTRO TECNOLÓGICO DE JOINVILLE  
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA DE SISTEMAS  
ELETRÔNICOS

Caio Gripp e Luiza Helena Kerscher

**FUSÃO SENSORIAL E ESTIMAÇÃO DE POSE COM FILTRO DE KALMAN**

Joinville  
2026

Caio Gripp e Luiza Helena Kerscher

## **FUSÃO SENSORIAL E ESTIMAÇÃO DE POSE COM FILTRO DE KALMAN**

Trabalho apresentado como requisito de avaliação da Disciplina de Estatística para análise de dados do Programa de Pós-Graduação em Engenharia de Sistemas Eletrônicos da Universidade Federal de Santa Catarina.

:

Joinville  
2026

## 1 INTRODUÇÃO

A determinação do estado de sistemas dinâmicos a partir de informações sensoriais constitui um problema relevante em diferentes aplicações da engenharia, incluindo robótica, navegação, sistemas autônomos e controle. Grandezas como posição, velocidade e orientação nem sempre podem ser observadas diretamente e, mesmo quando informações relacionadas a esses estados são disponibilizadas por sensores, as medições estão sujeitas a ruídos e outras fontes de incerteza. Dessa forma, a estimação de estados requer métodos capazes de extrair informações das observações disponíveis considerando as limitações associadas ao processo de medição.

Nesse contexto, as Unidades de Medida Inercial (*Inertial Measurement Units* – IMUs) são amplamente utilizadas para caracterizar o movimento de corpos rígidos. Esses dispositivos integram sensores como acelerômetros e giroscópios, que fornecem informações relacionadas, respectivamente, à aceleração específica e à velocidade angular. A partir dessas grandezas, é possível obter informações sobre a orientação do corpo ao longo do tempo.

Entretanto, a utilização isolada das informações fornecidas por cada sensor apresenta limitações. A velocidade angular medida pelo giroscópio pode ser integrada no tempo para determinar variações na orientação, porém erros presentes nessa medição também são acumulados durante a integração, podendo resultar em um desvio progressivo da estimativa. Por outro lado, em condições apropriadas, o acelerômetro permite obter uma referência de inclinação a partir das componentes associadas à aceleração gravitacional, mas suas medições são sensíveis a ruídos, vibrações e acelerações lineares. Dessa forma, os dois sensores apresentam características distintas e fornecem informações complementares para a estimação da atitude.

A combinação de informações provenientes de diferentes sensores é denominada fusão sensorial. Essa abordagem busca explorar as características complementares das fontes disponíveis para produzir uma estimativa mais adequada do estado do sistema do que aquela obtida a partir de uma única fonte de informação. Para isso, é necessário considerar não apenas os valores medidos, mas também as incertezas associadas às medições e ao modelo utilizado para representar a evolução do sistema.

Entre os métodos empregados para estimação de estados e fusão sensorial, destaca-se o Filtro de Kalman, originalmente proposto por Kalman (Kalman, 1960). O método fornece uma solução recursiva para a estimação do estado de sistemas dinâmicos lineares, combinando informações provenientes do modelo de evolução do sistema e das observações disponíveis. Sob as hipóteses do modelo linear-Gaussiano, o procedimento pode ser interpretado no contexto da inferência Bayesiana, em que uma estimativa *a priori* é atualizada a partir da informação fornecida por uma nova observação, resultando em uma estimativa *a posteriori* (Welch; Bishop, 2006; Barfoot,

2024).

Neste trabalho, esses conceitos são aplicados à fusão das informações provenientes de um giroscópio e de um acelerômetro para estimar a inclinação de um corpo rígido. Para isso, é desenvolvido um Filtro de Kalman Linear genérico, posteriormente aplicado a um modelo simplificado de estimação de atitude. Inicialmente, seu comportamento é avaliado por meio de dados sintéticos, permitindo comparar o sinal de referência, as medições simuladas e a estimativa filtrada, bem como quantificar o desempenho por meio do Erro Quadrático Médio. Posteriormente, o estimador é aplicado a dados inerciais adquiridos sequencialmente, permitindo avaliar seu funcionamento em uma condição dinâmica e analisar a influência das incertezas associadas ao processo e às medições sobre a estimativa obtida.

## 2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos estatísticos e matemáticos necessários à formulação do problema de estimação de estados abordado neste trabalho. Inicialmente, discutem-se a natureza incerta das medições e sua representação probabilística. Em seguida, são introduzidos os conceitos de variáveis aleatórias, distribuições Gaussianas, processos estocásticos e representação em espaço de estados. Por fim, apresenta-se a inferência Bayesiana e sua relação com o Filtro de Kalman Linear, estabelecendo a base teórica utilizada posteriormente na modelagem do problema de estimação de atitude.

### 2.1 MEDIÇÕES E INCERTEZAS

Em aplicações de engenharia e pesquisa científica, a compreensão quantitativa de fenômenos físicos frequentemente depende da aquisição e análise de dados experimentais. Para isso, grandezas físicas de interesse são observadas por meio de instrumentos e sensores. Entretanto, uma medição não constitui uma representação exata da grandeza investigada, uma vez que está sujeita a diferentes fontes de erro e incerteza associadas ao instrumento, ao procedimento experimental, às condições ambientais e ao próprio fenômeno observado.

De acordo com o Vocabulário Internacional de Metrologia (VIM), o resultado de uma medição está associado aos valores atribuídos a uma grandeza juntamente com as informações relevantes relacionadas a esses valores (JCGM, 2012). A incerteza de medição, por sua vez, caracteriza a dispersão dos valores que podem ser atribuídos à grandeza medida (Taylor; Kuyatt, 1994). Dessa forma, a informação fornecida por um sensor deve ser interpretada considerando-se a incerteza associada ao processo de observação.

Em um modelo simplificado, uma medição pode ser representada por

$$z_k = x_k + v_k, \quad (1)$$

em que  $x_k$  representa a grandeza ou estado de interesse no instante  $k$ ,  $z_k$  representa o valor observado e  $v_k$  corresponde ao termo aleatório associado ao erro de medição.

A Equação (1) não implica que toda fonte de incerteza possa ser descrita exclusivamente por um erro aditivo. Trata-se de uma representação probabilística simplificada, adequada à formulação considerada neste trabalho. O termo  $v_k$  é modelado como uma variável aleatória, permitindo representar estatisticamente a dispersão das observações em torno do valor esperado.

Essa abordagem fornece a base para métodos de estimação de estado, nos quais o objetivo não é assumir que uma observação corresponde exatamente ao es-

tado do sistema, mas utilizar as informações disponíveis e suas respectivas incertezas para obter uma estimativa probabilística da grandeza de interesse.

## 2.2 VARIÁVEIS ALEATÓRIAS E DISTRIBUIÇÃO GAUSSIANA

Uma variável aleatória associa valores numéricos aos possíveis resultados de um fenômeno sujeito à incerteza. Em problemas de medição e estimação, essa representação permite descrever matematicamente o comportamento de erros, perturbações e estados não conhecidos de forma exata.

Uma variável aleatória contínua  $V$  pode ser caracterizada por uma função densidade de probabilidade. Entre as distribuições utilizadas em problemas de estimação, destaca-se a distribuição Gaussiana, ou Normal, devido às suas propriedades matemáticas e à sua importância em modelos lineares de estimação (Barfoot, 2024).

Uma variável aleatória Gaussiana escalar é representada por

$$V \sim \mathcal{N}(\mu, \sigma^2), \quad (2)$$

em que  $\mu$  representa sua média e  $\sigma^2$  sua variância. A função densidade correspondente é dada por

$$p(v) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[ -\frac{(v - \mu)^2}{2\sigma^2} \right]. \quad (3)$$

A média representa o valor esperado da variável, enquanto a variância quantifica sua dispersão em torno desse valor. Para um ruído aleatório considerado não viesado, adota-se frequentemente

$$V \sim \mathcal{N}(0, \sigma^2). \quad (4)$$

Nesse caso, a hipótese de média nula indica que, em média, o termo aleatório não desloca sistematicamente a observação em uma direção específica.

Em problemas multivariados, o conceito de variância é generalizado por meio da matriz de covariância. Para um vetor aleatório  $\mathbf{x}$  com média  $\boldsymbol{\mu}$ , a matriz de covariância é definida por

$$P = \mathbb{E} \left[ (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T \right]. \quad (5)$$

Os elementos da diagonal principal de  $P$  correspondem às variâncias das componentes do vetor, enquanto os termos fora da diagonal representam as covariâncias entre diferentes componentes. Assim, uma distribuição Gaussiana multivariada pode ser representada por

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, P). \quad (6)$$

Essa representação é particularmente importante no Filtro de Kalman, pois tanto a estimativa do estado quanto sua incerteza são descritas, no caso linear-Gaussiano, por uma média e uma matriz de covariância.

No presente trabalho, assume-se que os termos aleatórios associados ao processo e às medições podem ser descritos por distribuições Gaussianas. Essa representação constitui uma hipótese de modelagem adotada para o problema e não implica que todo ruído presente em sistemas de medição possua necessariamente distribuição Gaussiana.

Essa hipótese será posteriormente combinada à linearidade dos modelos de estado e observação, permitindo a aplicação do Filtro de Kalman Linear.

### 2.3 PROCESSOS ESTOCÁSTICOS E REPRESENTAÇÃO EM ESPAÇO DE ESTADOS

Enquanto uma variável aleatória representa uma quantidade sujeita à incerteza, um processo estocástico descreve uma coleção de variáveis aleatórias indexadas por um parâmetro, frequentemente o tempo. Em sistemas dinâmicos, essa abordagem permite representar grandezas que evoluem temporalmente e cuja evolução está sujeita a incertezas (Barfoot, 2024).

Em problemas de estimação, busca-se inferir o estado de um sistema ao longo do tempo a partir de um modelo de sua dinâmica e de observações disponíveis. O estado pode ser entendido como um conjunto de variáveis capaz de caracterizar a condição do sistema em determinado instante e, juntamente com as entradas conhecidas, permitir a descrição de sua evolução temporal.

Para um sistema linear discreto, o modelo de evolução do estado pode ser escrito como

$$x_k = Fx_{k-1} + Bu_k + w_k, \quad (7)$$

em que  $x_k$  representa o vetor de estado no instante  $k$ ,  $F$  é a matriz de transição de estados,  $u_k$  representa uma entrada conhecida e  $B$  relaciona essa entrada à evolução do estado. O termo  $w_k$  representa o ruído de processo.

O ruído de processo representa perturbações, efeitos não modelados e demais fontes de incerteza relacionadas à evolução do sistema. Para o modelo linear-Gaussiano considerado neste trabalho, assume-se

$$w_k \sim \mathcal{N}(0, Q), \quad (8)$$

em que  $Q$  corresponde à matriz de covariância do ruído de processo.

A matriz  $Q$  não representa diretamente um erro determinístico do modelo, mas caracteriza estatisticamente a variabilidade atribuída ao termo  $w_k$ . Dessa forma, sua magnitude influencia o nível de incerteza associado à previsão do estado.

Além do modelo de evolução, é necessário definir como as grandezas observadas se relacionam ao estado. Para um sistema linear, o modelo de observação é expresso por

$$z_k = Hx_k + v_k, \quad (9)$$

em que  $z_k$  representa o vetor de observações,  $H$  é a matriz de observação e  $v_k$  representa o ruído associado à medição.

Adota-se para o ruído de medição

$$v_k \sim \mathcal{N}(0, R), \quad (10)$$

sendo  $R$  a matriz de covariância do ruído de medição.

As matrizes  $Q$  e  $R$  desempenham, portanto, papéis distintos. Enquanto  $Q$  caracteriza a variabilidade associada à evolução do estado,  $R$  caracteriza a variabilidade das observações em relação ao estado.

O modelo completo de espaço de estados considerado pode, então, ser escrito como

$$\boxed{x_k = Fx_{k-1} + Bu_k + w_k, \quad z_k = Hx_k + v_k.} \quad (11)$$

Para a formulação clássica adotada neste trabalho, considera-se ainda que os ruídos de processo e de medição possuem média nula, são mutuamente não correlacionados e não apresentam correlação temporal. Dessa forma,

$$E[w_k w_j^T] = \begin{cases} Q, & k = j, \\ 0, & k \neq j, \end{cases} \quad (12)$$

$$E[v_k v_j^T] = \begin{cases} R, & k = j, \\ 0, & k \neq j, \end{cases} \quad (13)$$

$$E[w_k v_j^T] = 0, \quad \forall k, j. \quad (14)$$

e suas covariâncias são caracterizadas por  $Q$  e  $R$ , respectivamente.

O estado inicial também é tratado probabilisticamente, sendo representado por

$$x_0 \sim \mathcal{N}(\hat{x}_0, P_0), \quad (15)$$

em que  $\hat{x}_0$  corresponde à estimativa inicial e  $P_0$  à incerteza associada a essa estimativa.



A representação em espaço de estados estabelece, portanto, dois elementos fundamentais do problema de estimação: um modelo probabilístico para a evolução do estado e um modelo probabilístico para as observações. A partir dessas informações, torna-se necessário determinar como o conhecimento sobre o estado deve ser atualizado quando uma nova medição é obtida. Essa atualização constitui um problema de inferência Bayesiana.

## 2.4 INFERÊNCIA BAYESIANA E TEOREMA DE BAYES

A estimação de uma grandeza física a partir de observações incertas constitui um problema de inferência. Em um sistema dinâmico, existe um conhecimento sobre o estado antes da aquisição de uma nova observação e, após a obtenção dessa informação, busca-se atualizar a estimativa de forma consistente com as incertezas envolvidas.

A inferência Bayesiana fornece uma estrutura matemática para realizar essa atualização. Sua formulação é baseada no conceito de probabilidade condicional. Para duas variáveis aleatórias  $X$  e  $Z$ , a densidade condicional de  $X$  dado  $Z = z$  é definida por

$$p(x|z) = \frac{p(x,z)}{p(z)}. \quad (16)$$

Como a distribuição conjunta também pode ser escrita como

$$p(x,z) = p(z|x)p(x), \quad (17)$$

obtem-se o Teorema de Bayes:

$$p(x|z) = \frac{p(z|x)p(x)}{p(z)}. \quad (18)$$

Na interpretação Bayesiana,  $p(x)$  representa a distribuição *a priori*, isto é, o conhecimento disponível sobre a variável antes da nova observação. O termo  $p(z|x)$  corresponde à verossimilhança (*likelihood*), que descreve a compatibilidade da observação com determinado valor do estado. A distribuição  $p(x|z)$  corresponde à distribuição *a posteriori*, que representa o conhecimento atualizado após a incorporação da observação. O termo  $p(z)$  atua como fator de normalização.

De forma proporcional,

$$p(x|z) \propto p(z|x)p(x). \quad (19)$$

Para um sistema dinâmico, é necessário considerar não apenas a observação atual, mas todo o conjunto de informações disponível até determinado instante. Definindo

$$z_{1:k} = z_1, z_2, \dots, z_k, \quad (20)$$

a distribuição posterior do estado no instante  $k$  é representada por

$$p(x_k | z_{1:k}). \quad (21)$$

Antes da incorporação da observação  $z_k$ , o conhecimento sobre o estado é descrito pela distribuição preditiva

$$p(x_k | z_{1:k-1}). \quad (22)$$

A atualização Bayesiana do estado é, então, expressa por

$$p(x_k | z_{1:k}) = \frac{p(z_k | x_k) p(x_k | z_{1:k-1})}{p(z_k | z_{1:k-1})} \quad (23)$$

Caso existam entradas conhecidas no modelo dinâmico, estas também condicionam a distribuição preditiva. Por simplicidade de notação, tais entradas são omitidas nas expressões probabilísticas apresentadas nesta seção.

A Equação (23) sintetiza a lógica fundamental da estimação recursiva:

$$\underbrace{p(x_k | z_{1:k-1})}_{a \text{ priori}} * \underbrace{p(z_k | x_k)}_{\text{verossimilhança}} \rightarrow \underbrace{p(x_k | z_{1:k})}_{a \text{ posteriori}}. \quad (24)$$

A distribuição *a priori* é obtida por meio do modelo dinâmico e representa o conhecimento disponível antes da nova observação. A verossimilhança é determinada pelo modelo de medição e caracteriza quão compatível é a observação obtida com cada possível estado. A combinação dessas duas informações resulta na distribuição *a posteriori*.

No modelo linear-Gaussiano considerado, a distribuição *a priori* do estado pode ser representada por

$$p(x_k | z_{1:k-1}) = \mathcal{N}(\hat{x}_k^-, P_k^-), \quad (25)$$

enquanto o modelo de observação

$$z_k = Hx_k + v_k, \quad v_k \sim \mathcal{N}(0, R), \quad (26)$$

estabelece a verossimilhança

$$p(z_k | x_k) = \mathcal{N}(Hx_k, R). \quad (27)$$

Dessa forma, a atualização Bayesiana consiste no produto entre duas distribuições Gaussianas, cuja combinação resulta novamente em uma distribuição Gaussiana.

Para o caso particular em que o modelo é linear e as distribuições envolvidas são Gaussianas, a distribuição posterior também permanece Gaussiana. Dessa forma, o processo de inferência pode ser realizado recursivamente utilizando apenas a média e a covariância das distribuições. Essa propriedade constitui a base probabilística do Filtro de Kalman Linear.

## 2.5 FILTRO DE KALMAN LINEAR

O Filtro de Kalman é um estimador recursivo desenvolvido para sistemas dinâmicos lineares, no qual as informações provenientes do modelo de evolução e das observações são combinadas de acordo com suas respectivas incertezas (Kalman, 1960; Welch; Bishop, 2006; Barfoot, 2024).

Sob as hipóteses do modelo linear-Gaussiano adotado neste trabalho, a distribuição do estado pode ser caracterizada em cada instante por uma média e uma matriz de covariância. O algoritmo é dividido em duas etapas principais: *predição* e *atualização*.

### 2.5.1 Etapa de Predição

A etapa de predição utiliza o modelo dinâmico para projetar a estimativa do estado do instante  $k - 1$  para o instante  $k$ . A média da distribuição *a priori* é calculada por

$$\hat{x}_{*k}^{-} = F\hat{x}_{*k-1} + Bu_k, \quad (28)$$

em que o sobrescrito  $(-)$  indica que a estimativa foi obtida antes da incorporação da nova observação.

A covariância associada à previsão é dada por

$$P_k^{-} = FP_{k-1}F^T + Q. \quad (29)$$

O termo  $FP_{k-1}F^T$  representa a propagação da incerteza existente no instante anterior através do modelo dinâmico, enquanto  $Q$  incorpora a incerteza adicional associada ao ruído de processo.

Assim, a distribuição preditiva pode ser representada por

$$x_k|z_{1:k-1} \sim \mathcal{N}(\hat{x}_k^{-}, P_k^{-}). \quad (30)$$

A etapa de predição corresponde, portanto, à determinação da distribuição *a priori* utilizada na inferência Bayesiana.

### 2.5.2 Etapa de Atualização

Após a obtenção da previsão, uma nova observação  $z_k$  é incorporada ao processo de estimação.

A diferença entre a observação realizada e a observação esperada a partir do estado previsto é denominada inovação:

$$y_k = z_k - H\hat{x}_k^- . \quad (31)$$

A covariância da inovação é calculada por

$$S_k = HP_k^- H^T + R . \quad (32)$$

O ganho de Kalman é então determinado por

$$K_k = P_k^- H^T S_k^{-1} . \quad (33)$$

A estimativa posterior do estado é obtida por

$$\hat{x}_k = \hat{x}_k^- + K_k y_k , \quad (34)$$

enquanto sua covariância é atualizada segundo

$$P_k = (I - K_k H) P_k^- . \quad (35)$$

A distribuição posterior pode, portanto, ser representada por

$$x_k | z_{1:k} \sim \mathcal{N}(\hat{x}_k, P_k) . \quad (36)$$

A etapa de atualização corresponde à incorporação da verossimilhança da nova observação à distribuição *a priori*, produzindo a distribuição *a posteriori*.

### 2.5.3 Interpretação do Ganho de Kalman

O ganho de Kalman determina a intensidade com que a inovação modifica a estimativa prevista. Sua magnitude depende da relação entre a incerteza associada à previsão, representada por  $P_k^-$ , e a incerteza associada à observação, representada por  $R$ .

Quando  $R$  assume valores elevados em relação à incerteza da previsão, a observação é considerada menos informativa e sua influência sobre a estimativa posterior é reduzida. Por outro lado, quando  $R$  é relativamente pequeno, maior peso é atribuído à informação fornecida pela medição.

De forma complementar, uma elevada incerteza na previsão, representada por  $P_k^-$ , aumenta a importância relativa da observação no processo de atualização. Assim, o ganho de Kalman não representa um fator arbitrariamente escolhido, mas uma

ponderação determinada a partir das covariâncias associadas às diferentes fontes de informação.

A matriz  $Q$  também exerce influência indireta sobre esse comportamento. Valores maiores de  $Q$  aumentam a incerteza propagada durante a predição e, consequentemente, podem aumentar a influência das observações nas atualizações posteriores. A seleção das matrizes  $Q$  e  $R$  é, portanto, relevante para o desempenho do estimador e será discutida posteriormente no contexto da implementação e análise dos resultados.

#### 2.5.4 Relação entre a Atualização Bayesiana e o Filtro de Kalman

A relação entre a inferência Bayesiana e a etapa de atualização do Filtro de Kalman pode ser demonstrada explicitamente considerando as hipóteses do modelo linear-Gaussiano. Conforme apresentado na Seção 2.4, a atualização Bayesiana do estado pode ser escrita, desconsiderando-se o termo de normalização, como

$$p(x_k | z_{1:k}) \propto p(z_k | x_k) p(x_k | z_{1:k-1}). \quad (37)$$

Antes da incorporação da nova observação, a distribuição *a priori* do estado é Gaussiana e pode ser representada por

$$p(x_k | z_{1:k-1}) = \mathcal{N}(\hat{x}_k^-, P_k^-). \quad (38)$$

Desconsiderando os termos constantes que não dependem de  $x_k$ , sua função densidade pode ser escrita na forma proporcional

$$p(x_k | z_{1:k-1}) \propto \exp \left[ -\frac{1}{2} (x_k - \hat{x}_k^-)^T (P_k^-)^{-1} (x_k - \hat{x}_k^-) \right]. \quad (39)$$

De forma análoga, considerando o modelo de observação

$$z_k = Hx_k + v_k, \quad (40)$$

com

$$v_k \sim \mathcal{N}(0, R), \quad (41)$$

a distribuição da observação condicionada ao estado, correspondente à verossimilhança, é dada por

$$p(z_k | x_k) = \mathcal{N}(Hx_k, R). \quad (42)$$

Assim, novamente omitindo os fatores independentes de  $x_k$ ,

$$p(z_k | x_k) \propto \exp \left[ -\frac{1}{2} (z_k - Hx_k)^T R^{-1} (z_k - Hx_k) \right]. \quad (43)$$

Substituindo as Equações (39) e (43) na atualização Bayesiana da Equação (37), obtém-se

$$p(x_k | z_{1:k}) \propto \exp \left\{ -\frac{1}{2} \left[ (x_k - \hat{x}_k^-)^T (P_k^-)^{-1} (x_k - \hat{x}_k^-) + (z_k - Hx_k)^T R^{-1} (z_k - Hx_k) \right] \right\}. \quad (44)$$

Expandindo os termos quadráticos que dependem de  $x_k$  e agrupando os termos de mesma ordem, obtém-se

$$p(x_k | z_{1:k}) \propto \exp \left\{ -\frac{1}{2} \left[ x_k^T \left( (P_k^-)^{-1} + H^T R^{-1} H \right) x_k - 2x_k^T \left( (P_k^-)^{-1} \hat{x}_k^- + H^T R^{-1} z_k \right) + C \right] \right\}, \quad (45)$$

em que  $C$  reúne os termos que não dependem de  $x_k$  e que, portanto, afetam apenas a normalização da distribuição.

A Equação (45) apresenta novamente a forma exponencial de uma distribuição Gaussiana. Comparando seus termos com a forma geral de uma Gaussiana multivariada, a matriz de covariância da distribuição *a posteriori* satisfaz

$$P_k^{-1} = (P_k^-)^{-1} + H^T R^{-1} H. \quad (46)$$

Consequentemente,

$$P_k = \left[ (P_k^-)^{-1} + H^T R^{-1} H \right]^{-1}. \quad (47)$$

A média da distribuição posterior é, por sua vez,

$$\hat{x}_k = P_k \left[ (P_k^-)^{-1} \hat{x}_k^- + H^T R^{-1} z_k \right]. \quad (48)$$

Aplicando identidades matriciais à Equação (47), a covariância posterior pode ser reescrita como

$$P_k = P_k^- - P_k^- H^T \left( H P_k^- H^T + R \right)^{-1} H P_k^-. \quad (49)$$

Definindo o ganho de Kalman por

$$K_k = P_k^- H^T \left( H P_k^- H^T + R \right)^{-1}, \quad (50)$$

a Equação (49) pode ser escrita na forma

$$P_k = (I - K_k H) P_k^- . \quad (51)$$

De forma equivalente, substituindo a definição de  $K_k$  na expressão da média posterior, obtém-se

$$\hat{x}_k = \hat{x}_k^- + K_k (z_k - H\hat{x}_k^-) . \quad (52)$$

O termo entre parênteses corresponde à inovação,

$$y_k = z_k - H\hat{x}_k^- , \quad (53)$$

de modo que a atualização também pode ser expressa por

$$\hat{x}_k = \hat{x}_k^- + K_k y_k . \quad (54)$$

Dessa forma, as equações de atualização do Filtro de Kalman não constituem uma regra de ponderação arbitrária. Elas resultam diretamente da aplicação do Teorema de Bayes ao caso em que a distribuição *a priori* e a verossimilhança são Gaussianas e o modelo de observação é linear (Welch; Bishop, 2006; Barfoot, 2024). A etapa de atualização do filtro corresponde, portanto, à obtenção analítica da distribuição *a posteriori*, cuja média é dada por  $\hat{x}_k$  e cuja covariância é dada por  $P_k$ .

### 2.5.5 Estrutura Recursiva do Filtro

O funcionamento do Filtro de Kalman pode ser resumido pelas etapas apresentadas na Tabela 1.

Tabela 1 – Etapas do Filtro de Kalman Linear.

| Etapa       | Grandeza                | Equação                               |
|-------------|-------------------------|---------------------------------------|
| Predição    | Estado                  | $\hat{x}_k^- = F\hat{x}_{k-1} + Bu_k$ |
| Predição    | Covariância             | $P_k^- = FP_{k-1}F^T + Q$             |
| Atualização | Inovação                | $y_k = z_k - H\hat{x}_k^-$            |
| Atualização | Covariância da inovação | $S_k = HP_k^- H^T + R$                |
| Atualização | Ganho de Kalman         | $K_k = P_k^- H^T S_k^{-1}$            |
| Atualização | Estado                  | $\hat{x}_k = \hat{x}_k^- + K_k y_k$   |
| Atualização | Covariância             | $P_k = (I - K_k H) P_k^-$             |

**Fonte:** Elaborado pela autora com base em (Kalman, 1960; Welch; Bishop, 2006).

Após a etapa de atualização, a estimativa  $\hat{x}_k$  e sua covariância  $P_k$  tornam-se as informações utilizadas no instante seguinte. Dessa forma, o procedimento é executado recursivamente à medida que novas observações são adquiridas.

Sob a perspectiva Bayesiana, o ciclo pode ser sintetizado por

Distribuição *a priori*  $\longrightarrow$  incorporação da observação  $\longrightarrow$  distribuição *a posteriori*  
 $\longrightarrow$  nova predição.

(55)

Assim, o Filtro de Kalman estabelece uma solução recursiva para a estimação de estados em sistemas lineares sujeitos às hipóteses probabilísticas adotadas. A aplicação dessa formulação ao problema específico de fusão entre giroscópio e acelerômetro requer a definição do vetor de estado, das entradas, das observações e das matrizes  $F$ ,  $B$ ,  $H$ ,  $Q$ ,  $R$ ,  $P_0$  e do estado inicial  $\hat{x}_0$ . Essas definições são desenvolvidas no capítulo seguinte.



### 3 MODELAGEM DO PROBLEMA DE ESTIMAÇÃO DE ATITUDE

Este capítulo apresenta a modelagem matemática utilizada para aplicar o Filtro de Kalman Linear ao problema de fusão sensorial entre giroscópio e acelerômetro. A partir das características de medição de cada sensor, define-se o estado de interesse, o modelo de evolução temporal e o modelo de observação. Em seguida, são estabelecidas as matrizes necessárias à implementação do estimador.

#### 3.1 HIPÓTESES E SIMPLIFICAÇÕES DO MODELO

A atitude de um corpo rígido é, de forma geral, uma grandeza tridimensional, podendo ser descrita por diferentes representações, como ângulos de Euler, matrizes de rotação ou quatérnios. Entretanto, o objetivo deste trabalho é avaliar os fundamentos estatísticos da fusão sensorial por meio de um Filtro de Kalman Linear. Dessa forma, adota-se um modelo simplificado de estimação de um único ângulo de inclinação.

Considera-se, portanto, que o movimento de interesse ocorre predominantemente em torno de um único eixo de rotação e que o estado a ser estimado corresponde ao ângulo  $\theta_k$  no instante discreto  $k$ .

Também se assume que o intervalo de amostragem  $\Delta t$  é conhecido e aproximadamente constante durante a aquisição dos dados.

Para o acelerômetro, considera-se que a componente predominante de aceleração utilizada na determinação da inclinação está associada ao campo gravitacional. Dessa forma, acelerações lineares adicionais são consideradas pequenas em relação à aceleração da gravidade durante as condições analisadas.

Os ruídos associados aos sensores são modelados como variáveis aleatórias de média nula. No contexto da simulação desenvolvida neste trabalho, esses termos são considerados Gaussianos e independentes entre si.

Essas hipóteses permitem formular o problema por meio de um modelo linear de espaço de estados, compatível com o Filtro de Kalman Linear apresentado no Capítulo 2.

#### 3.2 MODELO DO GIROSCÓPIO

O giroscópio mede a velocidade angular do corpo em torno de seus eixos de sensibilidade. Para o modelo unidimensional adotado, a medição fornecida pelo sensor pode ser representada por

$$\omega_{\text{gyro},k} = \omega_k + n_{g,k}, \quad (56)$$

em que  $\omega_k$  corresponde à velocidade angular real e  $n_{g,k}$  representa o ruído associado à medição do giroscópio.

No modelo adotado,

$$n_{g,k} \sim \mathcal{N}(0, \sigma_g^2), \quad (57)$$

sendo  $\sigma_g^2$  a variância associada ao ruído do sensor.

A relação entre a velocidade angular e a orientação é dada por

$$\omega(t) = \frac{d\theta(t)}{dt}. \quad (58)$$

Em tempo discreto, utilizando uma aproximação de primeira ordem, a orientação pode ser propagada segundo

$$\theta_k \approx \theta_{k-1} + \omega_k \Delta t. \quad (59)$$

Como a velocidade angular disponível ao estimador é obtida pelo giroscópio, utiliza-se

$$\theta_k \approx \theta_{k-1} + \omega_{\text{gyro},k} \Delta t + w_k, \quad (60)$$

em que  $w_k$  representa a incerteza efetiva associada à propagação do estado.

A utilização direta da leitura do giroscópio na integração implica que seu ruído também contribui para a incerteza da previsão. Considerando

$$\omega_{\text{gyro},k} = \omega_k + n_{g,k}, \quad (61)$$

a contribuição do ruído do giroscópio ao ângulo integrado é proporcional a  $\Delta t, n_{g,k}$ . Consequentemente, sua variância é proporcional a

$$\Delta t^2 \sigma_g^2. \quad (62)$$

Deve-se observar que  $\sigma_g^2$  representa a variância do ruído associado à medição da velocidade angular, e não necessariamente a variância total das leituras do giroscópio durante um movimento. Esta última pode conter também a variação física da velocidade angular do corpo.

Essa relação é utilizada posteriormente como referência para a definição da covariância do ruído de processo  $Q$ .

### 3.3 MODELO DO ACELERÔMETRO

O acelerômetro mede a aceleração específica ao longo de seus eixos. Em condições nas quais a aceleração linear do corpo é pequena em relação à aceleração gravitacional, as componentes medidas podem ser utilizadas para obter uma estimativa da inclinação do corpo.

Para uma determinada convenção de eixos, o ângulo pode ser obtido, por exemplo, por uma relação do tipo

$$\theta_{acc,k} = \arctan \left( \frac{a_{y,k}}{a_{z,k}} \right), \quad (63)$$

devendo a expressão ser ajustada conforme a orientação dos eixos adotada na implementação.

A estimativa angular obtida pelo acelerômetro pode ser modelada por

$$\theta_{acc,k} = \theta_k + n_{a,k}, \quad (64)$$

em que  $n_{a,k}$  representa o erro aleatório associado à estimativa angular fornecida pelo acelerômetro.

Adota-se

$$n_{a,k} \sim \mathcal{N} \left( 0, \sigma_a^2 \right). \quad (65)$$

Diferentemente do giroscópio, cuja informação é utilizada para propagar o estado ao longo do tempo, a estimativa obtida pelo acelerômetro é utilizada como uma observação do ângulo. Dessa forma, suas características estatísticas são incorporadas ao modelo por meio da covariância de medição  $R$ .

Nesse caso,  $\sigma_a^2$  corresponde à variância do erro associado à estimativa angular e não à variância total de  $\theta_{acc,k}$  durante o movimento, uma vez que esta última também contém a variação física do ângulo.

### 3.4 DEFINIÇÃO DO VETOR DE ESTADO

Considerando o modelo unidimensional adotado, o estado do sistema é definido exclusivamente pelo ângulo de inclinação:

$$x_k = \begin{bmatrix} \theta_k \end{bmatrix}. \quad (66)$$

A velocidade angular fornecida pelo giroscópio não é incluída como componente do vetor de estado. Ela é tratada como uma entrada utilizada na propagação temporal da estimativa.

Assim,

$$u_k = \begin{bmatrix} \omega_{gyro,k} \end{bmatrix}. \quad (67)$$

Essa escolha resulta em um modelo de primeira ordem, compatível com o objetivo de demonstrar a aplicação do Filtro de Kalman Linear à fusão de informações provenientes dos dois sensores.

### 3.5 MODELO DE TRANSIÇÃO DE ESTADO

A partir da relação de integração da velocidade angular,

$$\theta_k = \theta_{k-1} + \omega_{\text{gyro},k} \Delta t + w_k, \quad (68)$$

e comparando-a ao modelo geral

$$x_k = Fx_{k-1} + Bu_k + w_k, \quad (69)$$

obtêm-se as matrizes

$$F = \begin{bmatrix} 1 \end{bmatrix}, \quad (70)$$

e

$$B = \begin{bmatrix} \Delta t \end{bmatrix}. \quad (71)$$

Portanto, o modelo de transição adotado é

$$x_k = \begin{bmatrix} 1 \end{bmatrix} x_{k-1} + \begin{bmatrix} \Delta t \end{bmatrix} u_k + w_k. \quad (72)$$

O termo  $w_k$  incorpora as incertezas associadas à propagação do estado, incluindo, no modelo simplificado, a contribuição da incerteza da velocidade angular utilizada na integração e demais efeitos não representados explicitamente.

### 3.6 MODELO DE OBSERVAÇÃO

A estimativa de inclinação obtida a partir do acelerômetro é utilizada como observação do estado. Dessa forma,

$$z_k = \theta_{\text{acc},k}. \quad (73)$$

A relação entre a observação e o estado é dada por

$$z_k = Hx_k + v_k. \quad (74)$$

Como a observação corresponde diretamente ao ângulo de inclinação, define-se

$$H = \begin{bmatrix} 1 \end{bmatrix}. \quad (75)$$

Assim, o modelo de observação resulta em

$$\theta_{\text{acc},k} = \theta_k + v_k. \quad (76)$$

O termo  $v_k$  representa a incerteza associada à estimativa angular obtida a partir do acelerômetro.

### 3.7 DEFINIÇÃO DAS MATRIZES DO FILTRO

A partir das relações estabelecidas anteriormente, o modelo utilizado pelo Filtro de Kalman é definido por

$$F = \begin{bmatrix} 1 \end{bmatrix}, \quad B = \begin{bmatrix} \Delta t \end{bmatrix}, \quad H = \begin{bmatrix} 1 \end{bmatrix}. \quad (77)$$

A covariância do ruído de processo é representada por

$$Q = \begin{bmatrix} q \end{bmatrix}, \quad (78)$$

enquanto a covariância do ruído de medição é dada por

$$R = \begin{bmatrix} r \end{bmatrix}. \quad (79)$$

No modelo unidimensional,  $q$  e  $r$  correspondem a variâncias escalares.

Para o acelerômetro, a covariância de medição está associada à variância do erro presente na estimativa angular. No modelo unidimensional,

$$R = \sigma_a^2 = \text{Var}(n_a), \quad (80)$$

em que  $\sigma_a^2$  representa a variância do ruído associado à estimativa angular e  $n_a$  corresponde ao erro de medição do acelerômetro.

Quando uma referência  $\theta_{\text{ref}}$  é conhecida, essa grandeza pode ser estimada experimentalmente por

$$R \approx \text{Var}(\theta_{\text{acc}} - \theta_{\text{ref}}). \quad (81)$$

Quando a principal fonte de incerteza considerada na propagação é o ruído da velocidade angular do giroscópio, sua contribuição para a covariância do processo pode ser aproximada por

$$Q_0 = \Delta t^2 \sigma_g^2, \quad (82)$$

em que

$$\sigma_g^2 = \text{Var}(n_g) \quad (83)$$

representa a variância do ruído associado à medição da velocidade angular.

Essa expressão resulta da propagação da variância da velocidade angular através da integração discreta. Entretanto,  $Q$  pode também incorporar outras incertezas não representadas explicitamente no modelo, razão pela qual seu valor pode ser posteriormente ajustado durante a etapa de sintonia do filtro.

Além das matrizes estruturais, o algoritmo requer a definição de uma estimativa inicial do estado,

$$\hat{x}_0 = \begin{bmatrix} \hat{\theta}_0 \end{bmatrix}, \quad (84)$$

e de sua covariância inicial,

$$P_0 = \begin{bmatrix} p_0 \end{bmatrix}. \quad (85)$$

O parâmetro  $p_0$  representa o grau de incerteza atribuído à estimativa inicial. Valores reduzidos representam maior confiança no estado inicial, enquanto valores elevados indicam maior incerteza.

### 3.8 SÍNTESE DO MODELO ADOTADO

O modelo de estimação desenvolvido neste trabalho pode ser sintetizado pelas relações

$$x_k = x_{k-1} + \Delta t \omega_{\text{gyro},k} + w_k, \quad z_k = x_k + v_k, \quad (86)$$

com

$$w_k \sim \mathcal{N}(0, Q), \quad v_k \sim \mathcal{N}(0, R). \quad (87)$$

Os elementos utilizados pelo filtro são apresentados na Tabela 2.

Tabela 2 – Elementos do modelo de estimação de atitude.

| Elemento    | Definição                | Interpretação                              |
|-------------|--------------------------|--------------------------------------------|
| $x_k$       | $\theta_k$               | Ângulo de inclinação estimado              |
| $u_k$       | $\omega_{\text{gyro},k}$ | Velocidade angular medida pelo giroscópio  |
| $z_k$       | $\theta_{\text{acc},k}$  | Inclinação obtida a partir do acelerômetro |
| $F$         | $[1]$                    | Matriz de transição de estado              |
| $B$         | $[\Delta t]$             | Matriz de entrada                          |
| $H$         | $[1]$                    | Matriz de observação                       |
| $Q$         | $[q]$                    | Covariância do ruído de processo           |
| $R$         | $[r]$                    | Covariância do ruído de medição            |
| $P_0$       | $[p_0]$                  | Covariância inicial do estado              |
| $\hat{x}_0$ | $\hat{\theta}_0$         | Estimativa inicial da inclinação           |

**Fonte:** Elaborado pela autora.

Esse modelo estabelece a correspondência entre o problema físico de fusão sensorial e a formulação geral do Filtro de Kalman apresentada no Capítulo 2. A partir dessas definições, as matrizes e parâmetros podem ser fornecidos à implementação genérica do filtro, mantendo separada a formulação matemática do problema específico e a arquitetura computacional do estimador.

## 4 IMPLEMENTAÇÃO DO FILTRO DE KALMAN LINEAR

A implementação computacional do Filtro de Kalman foi desenvolvida em Python, mantendo-se separadas a formulação geral do estimador e sua aplicação específica ao problema de fusão sensorial. Essa organização permite que o algoritmo implementado seja utilizado em diferentes modelos lineares de espaço de estados, sem que sua estrutura interna dependa das características particulares do giroscópio ou do acelerômetro.

O código foi organizado em dois módulos principais. O arquivo `kalman_filter.py` contém a implementação genérica do Filtro de Kalman, enquanto o arquivo `imu_simulation.py` realiza sua aplicação ao problema de estimação de atitude. As operações matriciais necessárias à implementação do filtro são realizadas utilizando a biblioteca NumPy.

### 4.1 CLASSE GENÉRICA DO FILTRO DE KALMAN

A classe `KalmanFilter`, implementada no arquivo `src/kalman_filter.py`, recebe em seu construtor as matrizes que definem o modelo de espaço de estados:

```
KalmanFilter(F, B, H, Q, R, P0, x0)
```

em que  $F$  representa a matriz de transição de estados,  $B$  a matriz associada à entrada conhecida,  $H$  a matriz de observação,  $Q$  a matriz de covariância do ruído de processo,  $R$  a matriz de covariância do ruído de medição,  $P_0$  a covariância inicial da estimativa e  $x_0$  o estado inicial.

Durante a inicialização, as matrizes são convertidas para estruturas bidimensionais do NumPy, enquanto o vetor de estado é armazenado na forma de vetor coluna. A dimensão da matriz identidade utilizada posteriormente na atualização da covariância é determinada automaticamente a partir da dimensão do vetor de estado.

A matriz  $B$  também pode ser definida como `None` para sistemas que não possuam uma entrada conhecida. Dessa forma, a implementação não fica restrita ao problema de estimação de atitude desenvolvido neste trabalho.

A classe possui dois métodos principais, `predict(u)` e `update(z)`, correspondentes às etapas de predição e atualização do Filtro de Kalman.

### 4.2 IMPLEMENTAÇÃO DA ETAPA DE PREDIÇÃO

O método `predict(u)` realiza a propagação temporal da estimativa do estado. Quando existe uma entrada conhecida  $u_k$ , a operação executada corresponde a

$$\hat{x}_k^- = F\hat{x}_{k-1} + Bu_k. \quad (88)$$

No código, essa relação é implementada por

```
self.x = self.F @ self.x + self.B @ u
```

em que o operador @ representa a multiplicação matricial.

Caso não exista uma entrada conhecida, a propagação do estado é realizada somente por

$$\hat{x}_k^- = F\hat{x}_{k-1}. \quad (89)$$

Após a propagação da média, a matriz de covariância é atualizada segundo

$$P_k^- = FP_{k-1}F^T + Q, \quad (90)$$

implementada computacionalmente por

```
self.P = self.F @ self.P @ self.F.T + self.Q
```

A inclusão de  $Q$  representa a incerteza introduzida durante a evolução do sistema, conforme discutido na fundamentação teórica.

### 4.3 IMPLEMENTAÇÃO DA ETAPA DE ATUALIZAÇÃO

Após a predição, uma nova observação é incorporada por meio do método `update(z)`. Inicialmente, calcula-se a inovação

$$y_k = z_k - H\hat{x}_k^-, \quad (91)$$

implementada por

```
y = z - self.H @ self.x
```

Em seguida, calcula-se a covariância da inovação,

$$S_k = HP_k^-H^T + R, \quad (92)$$

e o ganho de Kalman,

$$K_k = P_k^-H^TS_k^{-1}. \quad (93)$$

Essas operações são implementadas por

```
S = self.H @ self.P @ self.H.T + self.R
K = self.P @ self.H.T @ np.linalg.inv(S)
```



A estimativa posterior é então obtida por

$$\hat{x}_k = \hat{x}_k^- + K_k y_k, \quad (94)$$

enquanto a matriz de covariância é atualizada por

$$P_k = (I - K_k H) P_k^-. \quad (95)$$

No código, essas operações são realizadas por

```
self.x = self.x + K @ y
self.P = (self._I - K @ self.H) @ self.P
```

Após a atualização, a propriedade `state` permite acessar o vetor de estado estimado em formato unidimensional.

#### 4.4 GENERALIDADE DA IMPLEMENTAÇÃO

A separação entre o algoritmo de estimação e o modelo físico constitui uma característica importante da implementação desenvolvida. A classe `KalmanFilter` não contém informações específicas sobre ângulos, giroscópios, acelerômetros ou unidades de medida inercial. O significado físico do estado, das entradas e das observações é definido externamente por meio das matrizes fornecidas ao construtor.

Como verificação adicional dessa generalidade, o arquivo `kalman_filter.py` contém uma aplicação independente na qual a mesma classe é utilizada para estimar uma grandeza escalar constante a partir de medições ruidosas, sem entrada de controle. Nesse exemplo, utiliza-se `B = None`, demonstrando que a implementação não está restrita ao modelo de fusão sensorial.

Para o problema investigado neste trabalho, a classe é instanciada pelo arquivo `imu_simulation.py` utilizando as matrizes específicas do modelo de estimação de atitude definido no Capítulo 3. Dessa forma, a arquitetura computacional preserva a correspondência entre as equações matriciais gerais do Filtro de Kalman e sua aplicação ao sistema estudado.

## 5 SIMULAÇÃO E VALIDAÇÃO

A validação inicial do estimador foi realizada por meio de uma simulação computacional com dados sintéticos. Essa abordagem permite conhecer previamente o estado real do sistema e controlar as características estatísticas dos ruídos introduzidos nas medições. Dessa forma, torna-se possível comparar diretamente o sinal de referência, as medições fornecidas pelos sensores simulados e a estimativa produzida pelo Filtro de Kalman.

A simulação foi implementada no arquivo `src/imu_simulation.py`, utilizando a classe genérica apresentada no Capítulo 4. O procedimento consiste na geração de uma trajetória angular de referência, na simulação das medições do giroscópio e do acelerômetro, na execução recursiva do filtro e na avaliação gráfica e quantitativa dos resultados.

### 5.1 GERAÇÃO DO SINAL DE REFERÊNCIA

Para representar a inclinação real do corpo rígido, adotou-se um sinal senoidal definido por

$$\theta(t) = A \sin(2\pi ft), \quad (96)$$

em que  $A$  representa a amplitude angular e  $f$  a frequência do movimento. Na simulação foram utilizados

$$A = 45^\circ \quad (97)$$

e

$$f = 0,25 \text{ Hz}. \quad (98)$$

O intervalo de amostragem foi definido como

$$\Delta t = 0,01 \text{ s}, \quad (99)$$

correspondendo a uma frequência de amostragem de 100 Hz. O tempo total de simulação foi de 20 s.

Como o giroscópio fornece informação de velocidade angular, a derivada analítica da trajetória foi utilizada como referência:

$$\dot{\theta}(t) = 2\pi f A \cos(2\pi ft). \quad (100)$$

Dessa forma, tanto o ângulo quanto a velocidade angular reais são conhecidos durante toda a simulação.

## 5.2 SIMULAÇÃO DO GIROSCÓPIO

O sinal do giroscópio foi simulado adicionando à velocidade angular real um viés constante e um ruído branco Gaussiano:

$$\omega_{\text{gyro},k} = \dot{\theta}_k + b + n_{g,k}, \quad (101)$$

em que  $b$  representa o viés do sensor e  $n_{g,k}$  representa o ruído aleatório da medição.

O ruído foi modelado segundo

$$n_{g,k} \sim \mathcal{N}(0, \sigma_g^2), \quad (102)$$

sendo adotado

$$\sigma_g = 0,3^\circ/\text{s}. \quad (103)$$

Além do ruído aleatório, foi introduzido um viés constante de

$$b = 3,5^\circ/\text{s}. \quad (104)$$

A inclusão do viés permite representar uma fonte de erro sistemático relevante em medições giroscópicas. Quando uma velocidade angular contendo esse erro é integrada ao longo do tempo, o erro acumulado pode produzir deriva na estimativa angular. Por esse motivo, o modelo utilizado neste trabalho inclui o viés do giroscópio como uma segunda variável de estado.

## 5.3 SIMULAÇÃO DO ACELERÔMETRO

A estimativa angular proveniente do acelerômetro foi simulada adicionando ruído Gaussiano diretamente ao sinal angular real:

$$\theta_{\text{acc},k} = \theta_k + n_{a,k}, \quad (105)$$

com

$$n_{a,k} \sim \mathcal{N}(0, \sigma_a^2). \quad (106)$$

Foi adotado

$$\sigma_a = 6^\circ, \quad (107)$$

representando uma medição angular com maior dispersão que aquela associada ao ruído instantâneo do giroscópio.

Dessa forma, os sensores simulados apresentam características complementares: o giroscópio fornece uma medição de velocidade angular com menor ruído aleatório, mas sujeita a viés, enquanto o acelerômetro fornece uma referência angular sem o acúmulo temporal desse viés, porém com maior dispersão instantânea.

#### 5.4 CONFIGURAÇÃO DO FILTRO DE KALMAN

O vetor de estado utilizado na simulação é composto pelo ângulo de inclinação e pelo viés do giroscópio:

$$x_k = \begin{bmatrix} \theta_k \\ b_k \end{bmatrix}. \quad (108)$$

A velocidade angular medida pelo giroscópio é utilizada como entrada conhecida:

$$u_k = \omega_{\text{gyro},k}. \quad (109)$$

Considerando que o ângulo evolui pela integração da velocidade angular corrigida pelo viés estimado e que o viés é aproximadamente constante entre amostras consecutivas, foram utilizadas as matrizes

$$F = \begin{bmatrix} 1 & -\Delta t \\ 0 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} \Delta t \\ 0 \end{bmatrix}. \quad (110)$$

O acelerômetro fornece uma observação direta do ângulo, mas não do viés. Assim,

$$H = \begin{bmatrix} 1 & 0 \end{bmatrix}. \quad (111)$$

A matriz de covariância do ruído de processo foi definida por

$$Q = \begin{bmatrix} (\sigma_g \Delta t)^2 & 0 \\ 0 & q_b \end{bmatrix}, \quad (112)$$

com

$$q_b = 10^{-4}. \quad (113)$$

Para os valores utilizados na simulação,

$$q_\theta = (0,3 \times 0,01)^2 = 9 \times 10^{-6} \text{ } ^\circ 2. \quad (114)$$

Consequentemente,

$$Q = \begin{bmatrix} 9 \times 10^{-6} & 0 \\ 0 & 10^{-4} \end{bmatrix}. \quad (115)$$

A matriz de covariância do ruído de medição foi determinada a partir da variância do ruído introduzido no acelerômetro:

$$R = [\sigma_a^2] = [36]. \quad (116)$$

As condições iniciais foram definidas como

$$\hat{x}_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad (117)$$

e

$$P_0 = \begin{bmatrix} 5 & 0 \\ 0 & 5 \end{bmatrix}. \quad (118)$$

## 5.5 EXECUÇÃO RECURSIVA

O filtro foi executado individualmente para cada amostra da série temporal. Inicialmente, a leitura de velocidade angular do giroscópio foi utilizada na etapa de predição:

```
kf.predict(u=[gyro_medido[k]])
```

Em seguida, a estimativa angular proveniente do acelerômetro foi incorporada pela etapa de atualização:

```
kf.update(z=[accel_medido[k]])
```

Após cada ciclo de predição e atualização, foram armazenados o primeiro componente do vetor de estado, correspondente ao ângulo estimado, e o segundo componente, correspondente à estimativa do viés do giroscópio.

Essa sequência estabelece computacionalmente a relação Bayesiana apresentada na fundamentação teórica. A informação dinâmica proveniente do giroscópio é utilizada para produzir a estimativa *a priori*, enquanto a medição do acelerômetro fornece a informação utilizada na atualização e obtenção da estimativa *a posteriori*.

## 5.6 RESULTADOS GRÁFICOS DA SIMULAÇÃO

Os resultados da simulação são apresentados na Figura 1. O primeiro gráfico compara o sinal angular real, a medição simulada do acelerômetro e a estimativa produzida pelo Filtro de Kalman.

Observa-se elevada dispersão das medições do acelerômetro em torno da trajetória de referência, comportamento compatível com o desvio padrão de  $6^\circ$  adotado na geração dos dados. Em contraste, a estimativa produzida pelo Filtro de Kalman acompanha de forma próxima a trajetória real, apresentando menor dispersão em relação ao sinal de referência.

O segundo gráfico apresenta a velocidade angular real e a leitura simulada do giroscópio. A diferença entre os sinais decorre da combinação entre o ruído Gaussiano e o viés constante de  $3,5^\circ/\text{s}$  introduzidos na simulação.

O terceiro gráfico apresenta a evolução da estimativa do viés do giroscópio. Partindo da condição inicial  $\hat{b}_0 = 0$ , observa-se a convergência progressiva da estimativa em direção ao valor utilizado para gerar os dados sintéticos.

A Figura 2 apresenta os erros absolutos da medição angular do acelerômetro e da estimativa obtida pelo Filtro de Kalman em relação ao sinal de referência.

A comparação mostra que o erro associado à medição bruta do acelerômetro apresenta maior dispersão ao longo da simulação. O erro da estimativa filtrada, por sua vez, permanece concentrado em valores significativamente menores durante a maior parte do intervalo analisado.

## 5.7 VALIDAÇÃO QUANTITATIVA

O desempenho do estimador foi avaliado quantitativamente por meio do Erro Quadrático Médio (EQM), definido por

$$EQM = \frac{1}{N} \sum_{k=1}^N (\hat{\theta}_k - \theta_k)^2, \quad (119)$$

em que  $\theta_k$  representa o ângulo real e  $\hat{\theta}_k$  a grandeza cuja precisão está sendo avaliada.

A aplicação dessa métrica à medição angular do acelerômetro e à estimativa produzida pelo Filtro de Kalman resultou nos valores apresentados na Tabela 3.

Tabela 3 – Erro Quadrático Médio obtido na simulação.

| Sinal avaliado   | EQM ( $^\circ^2$ ) |
|------------------|--------------------|
| Acelerômetro     | 35,8386            |
| Filtro de Kalman | 0,2495             |

**Fonte:** Elaborado pelos autores.

Para quantificar a redução relativa do erro, foi utilizada a relação

$$G_{EQM} = 100 \left( 1 - \frac{EQM_{KF}}{EQM_{acc}} \right), \quad (120)$$

resultando em




Figura 1 – Resultados da simulação da fusão sensorial: comparação entre o ângulo real, medido e filtrado, comportamento do giroscópio e estimação de seu viés.

**Fonte:** Elaborado pelos autores.




Figura 2 – Comparação do erro absoluto da medição do acelerômetro e da estimativa produzida pelo Filtro de Kalman.

**Fonte:** Elaborado pelos autores.

$$G_{EQM} \approx 99,30\%. \quad (121)$$

Portanto, para as condições adotadas na simulação, o Filtro de Kalman reduziu substancialmente o erro quadrático médio em relação à utilização direta da medição angular fornecida pelo acelerômetro.

A capacidade de estimação do viés também foi avaliada. O valor utilizado na simulação foi

$$b_{\text{real}} = 3,50^\circ/\text{s}, \quad (122)$$

enquanto o estado estimado ao final dos 20 s de simulação foi

$$\hat{b}_{\text{final}} = 3,48^\circ/\text{s}. \quad (123)$$

A diferença absoluta entre o valor real e o valor final estimado foi, portanto,

$$|b_{\text{real}} - \hat{b}_{\text{final}}| = 0,02^\circ/\text{s}. \quad (124)$$

A proximidade entre os valores indica que, nas condições simuladas, a combinação entre a informação dinâmica do giroscópio e a referência angular proveniente do acelerômetro permitiu estimar não apenas a orientação, mas também o viés introduzido na medição de velocidade angular.

## 5.8 DEFINIÇÃO DAS COVARIÂNCIAS $Q$ E $R$

As matrizes  $Q$  e  $R$  utilizadas na simulação foram definidas a partir das características estatísticas conhecidas dos ruídos empregados na geração dos dados



sintéticos.

Para o acelerômetro, o desvio padrão utilizado foi

$$\sigma_a = 6^\circ, \quad (125)$$

de modo que

$$R = \sigma_a^2 = 36^\circ{}^2. \quad (126)$$

Para o estado angular, a variância do ruído da velocidade angular do giroscópio foi propagada pelo intervalo de integração. Dessa forma,

$$q_\theta = (\sigma_g \Delta t)^2 = (0,3 \times 0,01)^2 = 9 \times 10^{-6}^\circ{}^2. \quad (127)$$

Para o estado associado ao viés, adotou-se

$$q_b = 10^{-4}. \quad (128)$$

Consequentemente,

$$Q = \begin{bmatrix} 9 \times 10^{-6} & 0 \\ 0 & 10^{-4} \end{bmatrix}. \quad (129)$$

Assim,  $R$  representa diretamente a variância do erro angular introduzido na medição simulada do acelerômetro, enquanto  $Q$  representa as incertezas associadas à propagação do estado angular e à evolução do viés do giroscópio.

Os valores empregados nesta etapa foram definidos a partir dos parâmetros estatísticos utilizados na própria geração dos sinais sintéticos. Portanto, a simulação permite avaliar o comportamento do estimador em uma condição na qual as características dos ruídos são conhecidas previamente.

## REFERÊNCIAS

BARFOOT, Timothy D. **State Estimation for Robotics**. 2. ed. [S.l.]: Cambridge University Press, 2024.

JOINT COMMITTEE FOR GUIDES IN METROLOGY. **International Vocabulary of Metrology**: Basic and General Concepts and Associated Terms (VIM). 3. ed. [S.l.], 2012. Disponível em: <https://www.bipm.org/en/doi/10.59161/jcgm200-2012>. Acesso em: 9 ago. 2026.

KALMAN, Rudolf E. A New Approach to Linear Filtering and Prediction Problems. **Journal of Basic Engineering**, v. 82, n. 1, p. 35–45, 1960.

TAYLOR, Barry N.; KUYATT, Chris E. **Guidelines for Evaluating and Expressing the Uncertainty of NIST Measurement Results**. Gaithersburg, 1994. Disponível em: <https://doi.org/10.6028/NIST.tn.1297>. Acesso em: 9 ago. 2026.

WELCH, Greg; BISHOP, Gary. **An Introduction to the Kalman Filter**. Chapel Hill, 2006. Disponível em: [https://www.cs.unc.edu/~welch/media/pdf/kalman\\_intro.pdf](https://www.cs.unc.edu/~welch/media/pdf/kalman_intro.pdf). Acesso em: 9 ago. 2026.